

PRODUCT REQUIREMENTS DOCUMENT

AdCheck

건강기능식품 광고 과장·오인 가능성 분석 Chrome Extension

건강기능식품 상세페이지의 광고 표현을 AI로 분석하고 공식 인정 기능성과 비교해, 소비자가 구매 전에 주의할 표현과 그 근거를 확인할 수 있도록 돕는 Chrome Extension입니다.

항목	내용
작성일	2026-09-14 (2026-09-25 업데이트 — MVP 구현 완료 반영)
프로젝트	EST 일경험 OJT - AdCheck
서비스 형태	소비자용 Chrome Extension
대상 분야	국내 온라인 건강기능식품 상품 상세페이지
팀	유주원 · 이효정 · 서호준 · 송하은
현재 단계	MVP 파이프라인 End-to-End 동작 확인 완료, 실사용 검증 및 성능 튜닝 단계

문서 목적

MVP의 제품 목표, 사용자 흐름, 기능 요구사항, 분석 파이프라인, 데이터·API·비기능 요구사항과 완료 기준을 하나의 기준 문서로 정리한다. 최초 작성(9/14) 이후 실제 구현·통합·트러블슈팅 과정에서 확정된 내용을 반영해 갱신한다.

목차

1. 프로젝트 개요 및 목표
2. 핵심 사용자와 사용자 플로우
3. MVP 범위 및 기능 요구사항
4. AI 1 차 분석 - Extraction
5. Backend 공식 데이터 확정
6. Rule Engine 및 공식 근거 연결
7. RAG / Grounding
8. AI 2 차 분석 - Comparison & Explanation
9. 최종 Finding 및 API 요구사항
10. 데이터 요구사항 및 기술 스택
11. 화면·비기능 요구사항
12. 역할 분담, 현재 상태, MVP 완료 기준
13. 트러블슈팅 사례 (신규)
14. 알려진 이슈 및 향후 개선 (신규)

1. 프로젝트 개요 및 목표

1.1 문제 정의

온라인 건강기능식품 광고에는 공식 인정 기능성보다 효과를 강하게 표현하거나, 질병 예방·치료 효과가 있는 것처럼 받아들여질 수 있는 문구가 사용된다. "먹기만 하면 한 달에 8kg 감량", "이제 고통스러운 허리 통증 끝"과 같은 표현이 실제로 유통되고 있으며, 소비자는 이를 구매 전에 스스로 검증할 방법이 마땅치 않다.

2026-09-25 갱신: 아래 실제 점검 결과와 통계로 문제의 규모와 소비자 확인 부담을 뒷받침한다.

항목	내용
점검명	2026 년 온라인 부당광고 합동점검 — 상습 위반업체 판매 게시물 점검
적발 건수	총 225 건
주요 위반 유형	건강기능식품 오인·혼동 104 건 (46%) 질병 예방·치료 오인 84 건 (37%) 소비자 기만 19 건 (8%) 기타(의약품 오인·거짓·과장) 18 건 (8%)
출처	식품의약품안전처, 온라인 부당광고 합동점검 결과 (2026.6.15)

항목	내용
점검명	2026 년 3 월 어린이 키 성장 광고 점검
적발 건수	식품·건강기능식품 부당광고 138 건 (매체별)
매체별 비중	온라인 판매사이트 75 건 (54%) SNS 63 건 (46%)
시사점	적발의 절반 이상이 온라인 판매사이트에서 나왔다.
출처	식품의약품안전처, 어린이 키 성장 부당광고 점검 결과 (2026.3.20)

AdCheck 의 우선 검토 대상 선정 근거

위 두 점검 결과를 근거로, AdCheck 는 "온라인 건강기능식품" 광고를 우선 검토 대상으로 선정했다.

1.1.1 구매자에게 남는 확인 부담

광고 하나를 믿기 위해, 소비자는 아래 네 가지를 직접 찾아 스스로 판단해야 한다.

- 01. 건강기능식품 인증마크 확인
- 02. 표시된 기능성 원료 및 함량 확인
- 03. 광고 표현의 적정성 판단
- 04. 나에게 적합한 제품인지 판단

결국 구매자는 여러 정보를 직접 확인하고 구매 여부를 판단해야 한다. (출처: 질병관리청 국가건강정보포털 「건강기능식품」)

1.1.2 기존 대응 방식의 한계

기존 현황	주체	방식	한계
정부·기관 사후 적발 공고	식약처·공정위	위반 사례 적발 후 보도자료 배포, 식품안전나라 등 공공 누리집에 공고	이미 늦은 사후 대처 — 구매· 피해 이후에 공고되어 구매 직전 예방이 어려움
판매자 대상 사전 심의	협회·오픈마켓(네이버· 쿠팡 등)	상품 등록 전 광고 시안 심의, 금칙어 필터링 등 사전 검수 운영	소비자용 도구 부재 — 판매자· 기업(B2B) 중심이라 구매자가 결제 직전에 쓸 수 없음
복잡한 법령·행정 누리집	법령·행정 누리집	기준과 규정이 여러 행정 체계와 전문 법률 용어로 흩어져 제공	어려운 법률 정보 — 소비자가 허위·과장 여부를 스스로 확인하기 어려움

AdCheck 가 채우는 공백

구매 순간 — 다른 창 없이 상품 페이지에서 결제 직전 클릭 한 번으로 분석

구매자 중심 — 판매자 관리용이 아닌 구매자의 판단을 지원

쉬운 판단 — 법조문 대신 왜 문제인지 쉬운 말로 요약

1.2 제품 목표

사용자가 건강기능식품 상품페이지를 벗어나지 않고 광고 표현과 공식 제품·원료 정보, 인정 기능성, 적용 Rule, 공식 근거를 한 화면에서 확인할 수 있도록 한다.

최종 사용자 가치

"이 표현을 믿어도 되는가?"를 단정적으로 판정하는 것이 아니라, 어떤 표현을 왜 다시 확인해야 하는지 공식 정보와 근거를 바탕으로 이해하기 쉽게 보여준다.

1.3 제품이 하지 않는 것

- 광고의 법적 위반 여부를 확정하지 않는다.
- 질병 치료 효과나 제품의 의학적 효능을 판정하지 않는다.
- 제품의 안전성을 확정하지 않는다.
- AI 가 존재하지 않는 공식 제품번호·기능성·법적 근거를 임의 생성하지 않는다.

사용자 화면에서는 "확인이 필요한 표현", "공식 인정 기능성보다 강한 표현일 가능성이 있습니다", "과장·오인 가능성이 있습니다", "현재 확인된 공식 정보에서 근거를 찾지 못했습니다"와 같은 표현을 사용한다.

갱신 — 소비자용 설명 문구 원칙 (신규)

실사용 검증 과정에서, AI 2 차(Explanation) 문구가 "~일 수 있습니다"류의 판단 유보형 서술로만 끝나면

소비자가 "그래서 어떻게 하라는 건지" 판단하기 어렵다는 점이 확인되었다.

이에 따라 설명 문구는 왜 문제인지 서술한 뒤, 반드시 소비자가 취할 수 있는 행동(예: "이 표현만 보고 효과를 확신하지 마세요", "실제 주원료와 기능성을 꼼꼼히 확인하세요")으로 마무리하도록 프롬프트 지시를 보강했다. 8.3 절 참고.

2. 핵심 사용자와 사용자 플로우

2.1 핵심 사용자

사용자	상황	필요
구매 직전 소비자	혈당·관절·눈 건강 등 건강기능식품 광고를 보고 구매를 고민함	광고 표현이 공식 인정 기능성과 얼마나 일치하는지 빠르게 확인
가족을 위한 구매자	부모님·가족에게 건강기능식품을 구매하기 전 효과 표현을 확인함	주의 표현과 그 이유를 쉬운 말로 확인

2.2 핵심 사용자 플로우

상품 상세페이지 접속
↓
AdCheck Extension 실행
↓
[분석하기]
↓
DOM Text + 상세 이미지 수집 (iframe 내부 포함)
↓
AI / 공식 데이터 / Rule / RAG 분석
↓
Side Panel 결과 표시 (심각도 HIGH·CAUTION 구분, 근거 법령 링크 포함)
↓
주의 표현 선택
↓
공식 기능성 + 판단 이유 + 출처 확인
↓
원래 상품페이지의 해당 표현 위치 확인

2026-09-25 갱신: 위 플로우는 실제 Chrome 확장에서 iframe 기반 마켓(예: 11 번가 등) 및 일반 상세페이지 다수를 대상으로 End-to-End 검증되었다. "결과 표시" 단계의 "최근 점검 기록"은 서버에 저장된 실제 분석 결과(analysisId)를 재조회하는 방식으로 동작하며, 과거 조회 시에도 그 시점의 실제 근거·설명을 그대로 다시 보여준다.

3. MVP 범위 및 기능 요구사항

3.1 P0 핵심 기능

ID	기능	요구사항	완료 기준	상태
FR-01	페이지 Evidence 수집	현재 페이지의 URL, 제목, Product 후보, DOM Text, selector, 상세 이미지 URL/alt 를 수집 (iframe 내부 상세 프레임 포함)	실제 건기식 상세페이지에서 텍스트·이미지 Evidence 생성, iframe 마켓에서도 누락 없음	완료
FR-02	AI 1 차 추출	Vision/OCR 로 Claim, Product/Ingredient Candidate, Risk Signal Candidate, source(위치 포함)를 구조화	Backend 가 사용할 JSON/DTO 반환, selector 위치정보 보존	완료
FR-03	공식 Product 식별	productReportNo 우선, 없으면 제품명+업체명 후보 조회	FOUND/AMBIGUOUS/NOT_FOUND 구분	완료
FR-04	Product-Ingredient 연결	사전 계산된 ProductIngredientMatch 우선 조회, 함량 표기 등 표기 차이를 흡수하는 정규화 매칭	확정 Product 에서 IngredientMaster 목록 반환	완료
FR-05	공식 기능성 조회	개별인정형·고시형 기능성 조회	Rule/AI 가 사용할 공통 기능성 결과 반환	완료
FR-06	Rule Engine	COMMON/원료별 Rule 조건·예외 평가 및 ReferenceSource 연결, 판정 근거 코드 구분	RuleMatch + 공식 근거 Metadata 반환, 매칭된 규칙 전체 목록(FindingRule[]) 보존	완료
FR-07	RAG Grounding	ReferenceSource 문서에서 Claim 관련 근거 문단 검색	관련 Evidence 및 출처 확보	완료
FR-08	AI 2 차 비교·설명	Claim 과 Official Function 을 비교하고 Rule/RAG 근거 기반 설명 생성, 행동 유도형 문구	소비자용 비교 결과와 설명 반환	완료
FR-09	Finding 통합	각 단계 결과를 Findings 로 조립·저장, 정보 손실 없이 판정 규칙 전체 보존	COMPLETED 결과 조회 가능	완료
FR-10	결과 표시·하이라이트	Side Panel 에 주의 표현/공식 기능성/근거 표시 및 원문 위치 연결	사용자가 결과에서 원문 위치를 찾을 수 있음	완료

2026-09-25 갱신: FR-01~10 전체가 실제 Chrome Extension ↔ Backend 연동으로 동작하는 것을 확인했다. 최초 작성 시점에는 FR-06(Rule Engine)·FR-07(RAG)·FR-08(AI 2 차)이 Mock 으로 대체되어 있었으나, 현재는 모두 실제 구현으로 교체되었다.

4. AI 1 차 분석 - Extraction

Gemini 를 이용해 DOM Text 와 상세 이미지를 이해하고, 이후 공식 데이터 조회와 Rule Engine 에 사용할 후보를 구조화한다.

4.1 입력

- DOM Text Evidence (블록 단위, 각 블록은 원본 selector 를 보존)
- 상세 이미지 URL 또는 서버가 접근 가능한 이미지 데이터
- 페이지 URL / Title / Selector 등 Source 정보

4.2 출력 요구사항

필드	의미	주요 속성
claims	광고가 주장하는 효능·기능성 표현	claimId, claimText, source(selector 포함), sourceLineIndex
productCandidates	공식 제품 식별 후보	productReportNo?, productName?, companyName?, confidence?, source
ingredientCandidates	페이지에서 읽은 원료 후보	rawText(함량 표기 포함 가능), confidence?, source
riskSignalCandidates	Rule 기준상 확인이 필요한 표현 후보	claimId, signalType, text, confidence?, source

책임 경계

AI 1 차는 "후보 추출" 단계다. Product·Ingredient·Rule 을 공식 확정하지 않으며, productReportNo 를 찾지 못한 경우 임의로 추정해 생성하지 않는다.

4.3 OCR 이원화 (갱신)

초기 설계는 Gemini 단일 OCR 이었으나, 실측 결과 Google Cloud Vision 이 이미지 문자 추출 시간과 정확도 모두에서 우수해 아래와 같이 이원화했다.

항목	내용
기본 엔진	Google Cloud Vision (이미지 문자 추출)
폴백 엔진	Gemini — Vision 호출 실패 또는 API 키 미설정 시에만 해당 이미지를 재처리
OCR 결과 캐시	이미지 URL 단위 메모리 캐시(CachingOcrService), TTL 7 일, 최대 2,000 건, 서버 재시작 시 초기화. Vision→Gemini 폴백 앞단에서 동작해 같은 이미지를 반복 호출하지 않도록 함
실측 개선	이미지 문자 추출 시간 약 44 초 → 12.6 초, Gemini 대비 추출 글자수 약 96% 수준 유지, 한쪽 엔진만 빈 결과를 낸 이미지 0 장
위치정보(selector) 유지	AI 1 차에 전달하는 텍스트 블록을 하나로 병합하지 않고 sourceLineIndex

항목	내용
	로 역참조하도록 수정해, 결과 화면의 "원문 위치 이동" 기능이 항상 정상 selector 를 갖도록 함

5. Backend 공식 데이터 확정

5.1 Product Identification

```

Product Candidate
↓
1 순위: productReportNo exact lookup
↓
(없으면) 2 순위: productName + companyName 후보 조회
↓
FOUND / AMBIGUOUS / NOT_FOUND

```

공식 Product 가 확정되면 analyses.product_id 에 저장한다.

5.2 Ingredient Matching

확정 Product 에서 사전 계산된 ProductIngredientMatch 를 우선 사용한다. 정확한 인정번호·동의어를 우선하며, 정규화된 이름은 하나의 Ingredient 로 유일하게 확정되는 경우에만 자동 매칭한다. 여러 후보가 남으면 REVIEW_REQUIRED 로 처리한다.

Fallback

사전 계산된 ProductIngredientMatch 가 없는 경우에 한해 runtime Ingredient Matching 을 fallback 으로 사용한다. 매칭 알고리즘 구현은 AI 담당, 호출·결과 사용 결정은 Backend 가 담당한다.

갱신 — 함량 표기 정규화 (신규)

AI 1 차가 원료명을 추출할 때 "EPA 및 DHA 함유 유지 1,000mg"처럼 함량 단위를 포함해 가져오는 반면, 매칭 로직은 공백 제거·소문자화만 수행해 표준명("EPA 및 DHA 함유 유지")과 정확히 일치하지 않아 원료 확정이 구조적으로 실패하던 문제가 있었다.

매칭 직전에 이름 끝의 "숫자+단위(mg, g, %, µg, IU 등)"를 정규식으로 제거하는 전처리를 추가해 해결했다. 괄호 안 내용은 기존 원칙대로 제거하지 않으며, 전처리 후에도 완전일치만 허용해 유사매칭(fuzzy match)으로 확장하지 않는다.

이 수정 전에는 원료별 Rule 41 개가 실제 트래픽에서 한 번도 발동하지 않는 상태였다.

5.3 Official Function 조회

```

IngredientMaster
↓
FunctionalIngredient (개별인정형) + NotifiedIngredient (고시형)
↓
Official Functions

```

Backend 는 데이터 종류의 차이를 내부적으로 유지하되, Rule/AI 가 사용하기 쉬운 공통 읽기 모델로 반환한다.

6. Rule Engine 및 공식 근거 연결

Rule Engine 은 AI 가 제시한 Risk Signal 을 최종 판정으로 사용하지 않고 실제 Rule 의 적용 조건·예외·필요 Evidence 를 확인한다.

6.1 입력

- Claims
- Risk Signal Candidates
- 확정 Ingredient
- Official Functions

6.2 처리 흐름

```
COMMON Rule + Ingredient-specific Rule 선택
↓
적용 조건 확인
↓
예외 조건 확인
↓
MATCHED / NOT_MATCHED / REVIEW_REQUIRED
↓
RuleSource → ReferenceSource
↓
RuleMatch + 공식 근거 Metadata
```

하나의 Claim 에는 여러 Rule 이 동시에 적용될 수 있다. AI Risk Signal 은 Rule Engine 의 힌트이며, 자동 판단 가능한 COMMON Rule 은 Risk Signal 누락 시에도 Claim 자체를 검사할 수 있어야 한다.

RAG 와의 경계

Rule Engine 은 "어떤 공식 문서가 이 Rule 의 근거인가?"까지 연결한다. 해당 문서 안에서 현재 Claim 과 관련된 실제 문단을 찾는 일은 RAG 가 담당한다.

6.3 판정 결과 조립 — 정보 손실 방지 (신규)

한 Claim 에 여러 Rule 이 동시에 매칭되는 구조이므로, 조립 단계에서 두 가지 문제가 순차적으로 발견·해결되었다.


구분	내용
문제 1 — 폐기	여러 Rule 이 매칭돼도 대표 Rule 1 개만 화면에 반영되고 나머지 판정 정보는 저장되지 않던 문제. FindingRule[] 필드를 신설해 매칭된 Rule 전체(ruleCode, 판정 상태, 사유, 근거 포함)를 보존하도록 수정했다. 기존

구분	내용
	riskLevel/category/message/sources 등 대표 Rule 기준 필드는 하위호환을 위해 그대로 유지한다.
문제 2 — 오염	정보 손실을 막기 위한 1 차 수정(카테고리별 상위 노출) 과정에서, 아직 세부 판단 로직이 구현되지 않은 Rule(reasonCode: UNSUPPORTED_RULE 등)까지 "판단했지만 애매한 결과"와 동일하게 취급되어, 서로 다른 광고 문구가 같은 카테고리로 표시되는 오염이 발생했다. reasonCode 를 기준으로 "판단 시도 자체를 하지 않은 것"과 "판단했지만 애매한 것(genuine REVIEW_REQUIRED)"을 구분하고, 전자는 Finding 생성에서 제외하는 대신 별도로 집계하도록 재설계했다.
미평가 건수 집계	판단 범위 밖(미구현 Rule·데이터 부족 등)으로 분류된 Claim 은 위험 Finding 으로 세지 않고 summary.unevaluatedClaimCount 로 별도 노출한다. 화면과 API 응답 모두에서 실측 확인 완료.

검증: 신규 테스트 작성 후 회귀 없이 통과, 실제 분석 결과에서 오염 현상 소거 확인. 이후 Rule 수가 30 개에서 50 개로 확장되는 동안에도 이 조립 로직은 추가 수정 없이 안정적으로 동작했다.

7. RAG / Grounding

Rule Engine 이 연결한 ReferenceSource 를 기준으로 현재 Claim 과 관련성이 높은 근거 문단을 검색한다.



책임	주체
어떤 Rule 이 적용되는가	Rule Engine
그 Rule 의 공식 근거 문서는 무엇인가	Rule Engine
그 문서의 어떤 문단이 현재 Claim 과 관련 있는가	RAG
그 근거를 소비자가 이해할 수 있게 설명	AI 2 차 LLM

2026-09-25 갱신: RagRetrievalService 가 생성자 시점에 청크·임베딩을 1 회 로드해 메모리에 보관하며, 요청마다 질의 임베딩 1 회와 메모리 내 유사도 비교만 수행한다(재로드 없음). 근거 표시 (sources) 화면에는 "URL + 조문 설명"이 세미콜론으로 병기된 원본 데이터를 조문 단위로 분리해 각각 클릭 가능한 링크로 표시하도록 프론트에서 파싱한다.

8. AI 2 차 분석 - Comparison & Explanation

RAG 검색 이후 Gemini 가 광고 Claim 과 공식 인정 기능성을 의미적으로 비교하고, Rule/RAG 근거를 바탕으로 소비자용 설명을 생성한다.

8.1 입력

- Claim
- 확정 Product / Ingredient
- Official Functions
- RuleMatches
- RAG Evidence

8.2 비교 예시

예시

광고: "콜레스테롤을 정상화합니다"

공식 기능성: "혈중 콜레스테롤 개선에 도움을 줄 수 있음"

→ 광고 표현이 공식 인정 범위보다 효과를 더 강하게 단정했는지 의미적으로 비교한다.

8.3 출력

항목	내용
comparisonStatus	WITHIN_OFFICIAL_RANGE / STRONGER_THAN_OFFICIAL / NO_OFFICIAL_BASIS / REVIEW_REQUIRED 등
officialFunction	Backend 가 조회한 공식 기능성
reason	Claim 과 공식 기능성의 의미 차이 요약
explanation	Rule 과 Evidence 에 근거한 소비자용 설명 — 왜 문제인지 서술 후 행동 유도형 결론으로 마무리 (갱신, 아래 참고)

갱신 — explanation 종결 방식 (신규)

이전: "...효과를 오인하게 만들 수 있습니다." 처럼 판단을 유보하는 서술로 끝나, 소비자가 다음에 무엇을 해야 하는지 알기 어려웠다.

이후: "...이 표현만 믿고 구매를 결정하지 마세요", "...실제 주원료와 기능성을 꼼꼼히 확인하세요"처럼, 왜 문제인지 설명한 뒤 소비자가 취할 행동을 명시하는 문장으로 마무리하도록 프롬프트 지시를 수정했다. 2~3 문장 이내로 간결하게 작성하도록 길이도 함께 제한했다.

실제 claim 두 건으로 전/후 비교 테스트를 실행해 의도한 대로 변경되었음을 확인했다.

중요

RAG 는 근거를 "찾아오는" 역할이고, 최종 자연어 설명은 AI 2 차 LLM 에서 생성한다. LLM 은 제공된 Official Function, RuleMatch, Evidence 범위를 넘어 새로운 공식 사실을 만들지 않는다. ruleMatches 가 있으면 참고만 하고 severity/ruleCode 를 다시 판정하지 않는다.

9. 최종 Finding 및 API 요구사항

9.1 Finding 구성

Claim + Official Functions + RuleMatches + AI Comparison + Grounding Evidence + AI Explanation



Finding (대표 필드) + rules: FindingRule[] (매칭된 Rule 전체, 신규)

세부 필드명은 Backend API Contract 확정 시 조정할 수 있으나, Claim-Rule-ReferenceSource-Evidence 관계를 추적할 수 있어야 한다. rules 필드는 클라이언트가 무시해도 기존 화면이 동일하게 동작하는 additive 구조로 설계했다(하위호환).

9.2 비동기 분석 API

이미지 처리, Gemini, RAG 가 포함되므로 최종 외부 API 는 분석 요청과 결과 조회를 분리한다.

API	응답/역할
POST /api/v1/analyses	재사용 가능한 결과가 있으면 200 OK + REUSED, 없으면 202 Accepted + analysisId + PENDING/PROCESSING
GET /api/v1/analyses/{id}	PENDING / PROCESSING / COMPLETED / FAILED 상태와 완료 결과 조회 (구현 완료, Extension 폴링 연동 완료)

9.3 결과 재사용(TTL) 정책 — 갱신: 차등 TTL 구현 완료

동일 상품을 여러 사용자가 반복 분석할 경우 AI 호출 비용을 줄이기 위해, 같은 normalizedUrl + contentHash + pipelineVersion 조합에 COMPLETED 결과가 있으면 재사용한다.

최초 계획 단계에서는 TTL 7 일 단일값이었으나, 위반(Finding) 존재 여부에 따라 차등 적용하도록 구현을 완료했다: 위반이 있는 결과는 7 일, 위반이 없는(clean) 결과는 30 일 보관한다. 위반 이력 상품은 판매자가 문구를 바꿔 재시도할 가능성이 높은 그룹이라 더 자주 재검사하고, clean 상품은 상대적으로 길게 캐시해 비용을 아낀다.

OCR 결과 캐시(이미지 단위, 4 절 참고)와는 별개의 캐시다 — 하나는 분석 결과 전체를 DB 에 보관하고, 하나는 이미지→텍스트 변환 결과만 서버 메모리에 보관한다.

알려진 한계(blind spot): contentHash 는 상품명·DOM Text·이미지 URL·alt 텍스트로 생성되므로, 이미지 URL 은 그대로 두고 실제 이미지 내용만 교체되는 경우를 현재 구조로는 감지하지 못한다. 또한 광고 추적 파라미터(예: 네이버페이 결제 위젯 id 에 포함된 타임스탬프)가 URL 정규화를 통과해 매번 다른 contentHash 를 만들어 캐시가 무력화되던 문제를 발견해 URL 정규화 로직을 보강했다.

중기 방향: 이미지 콘텐츠 해시(pHash 등)를 contentHash 에 포함시켜, TTL 과 무관하게 실제 이미지가 바뀌면 즉시 캐시를 무효화하는 방식으로 blind spot 자체를 줄이는 것을 목표로 한다.

9.4 Background Job 내부 흐름

AI 1 차 Extraction

↓
Backend 공식 데이터 확정
↓
Rule Engine
↓
RAG Grounding
↓
AI 2 차 Comparison + Explanation
↓
Finding 저장
↓
COMPLETED

현재 구현 상태 — 갱신

POST /api/v1/analyses 가 제출·재사용·진행중 조회를 모두 처리한다. 요청이 오면 정규화 URL + 콘텐츠 해시 + 파이프라인 버전으로 재사용 여부를 먼저 판단하고, 신규 건은 PENDING 저장 후 전용 스레드풀에서 Background Job 이 비동기로 실제 파이프라인(Extraction → 공식 데이터 확정 → Rule Engine → RAG → AI 2 차 → Finding 저장)을 실행해 DB 에 영속화한다.

GET 상태 조회 엔드포인트와 Extension 폴링 UI 까지 완료되어, 최초 작성 시점에 남아 있던 항목이 모두 구현되었다. 규칙 평가 단계의 동시성을 4 에서 12 로 확장해 규칙 평가 소요시간을 약 52% 단축(5.9 초 → 2.9 초)했다.

10. 데이터 요구사항 및 기술 스택

10.1 Canonical Data

데이터	규모	주요 용도
Product	45,970 건	공식 제품 식별
IngredientMaster	607 건	원료 canonical 기준
IngredientSynonym	3,302 건	원료 표기 매칭
FunctionalIngredient	773 건	개별인정형 기능성
NotifiedIngredient	96 건	고시형 기능성
ProductIngredientMatch	176,447 건	제품-원료 사전 계산 매핑
Rule	71 건	광고 표현 검토 (COMMON 30 / 원료별 41)
ReferenceSource	15 건	Rule 공식 근거 문서 메타데이터
AdCase	38 건	광고 심의 사례 참조

ProductIngredientMatch 는 동의어 데이터와의 버전 불일치를 해소하기 위해 전체 176,447 건을 재계산한 FINAL canonical 데이터를 사용한다.

갱신 — 시드 데이터 적재 완료

최초 작성 시점에는 위 표가 "목표 규모"였고 DB 적재 코드가 없는 상태였으나, 현재는 Flyway 마이그레이션으로 전체 데이터가 DB 에 적재되어 운영 중이며, 위 건수는 실제 DB 조회로 재확인한 값이다. PostgreSQL 에 저장되는 데이터 카테고리는 제품·원료·기능성·규칙 외에 광고 심의 사례(AdCase)와 근거 출처(ReferenceSource)를 포함해 총 7 개 카테고리다.

10.2 기술 스택

영역	기술
Frontend	React, TypeScript, Vite
Extension	Chrome Extension API / Manifest V3
Backend	Java 21, Spring Boot 4.1.1
ORM	Spring Data JPA (N+1 방지를 위해 @EntityGraph 적용)
Database	PostgreSQL
Migration	Flyway
AI	Google Gemini API (Claim Extraction, Semantic Comparison, Explanation, Embedding) + Google Cloud Vision (OCR 기본 엔진, Gemini 는 폴백)
RAG	Embedding + 인메모리 Retrieval (서버 기동 시 1 회 로드)
캐시	결과 재사용 캐시(DB, TTL 7·30 일 차등) + OCR 결과 캐시(메모리, TTL 7 일, 최대 2,000 건)
Backend Test	Gradle, JUnit
Collaboration	GitHub, Notion, Figma

11. 화면·비기능 요구사항

11.1 화면 상태

상태	화면 요구사항
분석 전	분석 가능 여부와 [분석하기] CTA 표시
PENDING	"분석을 준비하고 있어요" 등 대기 상태 표시
PROCESSING	"상품페이지의 광고 표현을 분석하고 있어요" 등 진행 상태 표시
COMPLETED	주의 표현, 심각도(HIGH·CAUTION), 공식 기능성, 비교 설명, 근거·출처(클릭 가능한 법령 링크), 원문 위치 이동 제공

상태	화면 요구사항
FAILED	실패 안내와 재시도 기능 제공. API 한도 소진 등 서버 정상 상태의 실패도 "분석 서버에 연결할 수 없어요"로 동일 안내되는 점은 향후 개선 대상(13 절)

11.2 비기능 요구사항

분류	요구사항
보안	Gemini/API Key 는 Extension 에 포함하지 않고 서버에서 관리한다. 로컬 개발 시에는 .env 파일 + .gitignore 로 버전관리에서 제외한다.
정확성	AI 후보를 공식 확정값으로 바로 사용하지 않으며, 불확실한 매칭은 억지로 확정하지 않는다.
Grounding	AI 설명은 공식 기능성, Rule, Evidence 범위 안에서 생성한다.
성능	장시간 분석을 HTTP 요청에서 분리하고 Polling 으로 상태를 조회한다. 규칙 평가는 병렬 처리(동시성 12)로 대기시간을 단축한다.
DB 조회	Rule-ReferenceSource 조회는 @EntityGraph 기반 Batch/JOIN 으로 처리해 N+1 을 방지한다.
추적성	Finding 에서 Claim → Rule → ReferenceSource → Evidence 연결을 추적할 수 있어야 한다. ruleCode 는 FindingRule[]을 통해 보존된다.

12. 역할 분담, 현재 상태, MVP 완료 기준

12.1 역할 분담

이름	역할	주요 책임
유주원	Backend + Leader	Spring Boot API, DB 설계·적재, Product/Ingredient/Function 공식 조회, Rule Engine 연동, Finding 조립 로직, AI·Frontend 통합, Pipeline orchestration, 팀 브랜치 통합
이효정	Frontend + Data	Chrome Extension, DOM Text·이미지 수집(iframe 포함), Backend API 연동, Rule 데이터 구조화
서호준	AI	Vision/OCR 이원화, Claim·후보 추출, Gemini 연동, Embedding/RAG, 의미 비교 및 소비자 설명, Rule Judge 정확도·성능 개선
송하은	Design + Frontend	UI/UX, AdCheck Side Panel, 상태별 화면·문구 및 결과 화면, 심각도 범례·근거 표시 UI


12.2 현재 구현 상태 (전면 갱신)

영역	상태
Backend 기반 (Spring Boot, PostgreSQL, Flyway, JPA)	완료
분석 요청 오케스트레이션 (재사용 판정 + PENDING 생성 + Async 실행)	완료 — 실제 파이프라인과 연결
Product Identification + Product→Ingredient + Official Function	완료 — 분석 파이프라인에 연결됨, 함량 표기 정규화 반영
Rule Engine	완료 — 71 개 Rule(COMMON 30 + 원료별 41), 코드로직/정규식/AI 평가 3 갈래 평가, FindingRule[]로 전체 보존
AI 실제 연동 / RAG	완료 — Gemini + Google Cloud Vision 이원화 OCR, RAG 123 개 청크 인메모리 검색
Async Job / Result Persistence	완료 — 재사용 캐시 TTL 7 일(위반)·30 일(clean) 차등 적용, DB partial unique index 로 동시 중복 방지
GET 상태 조회 API / Extension 폴링	완료
Canonical 시드 데이터 적재 (CSV → DB)	완료 — Flyway 로 전량 적재, 실 DB 조회로 건수 재확인
Finding 정보 손실/오염 방지, 미평가 건수 집계	완료 — 회귀 테스트 및 실측 검증 완료
selector(원문 위치) 보존	완료 — sourceLineIndex 기반 역참조로 수정
결과 UI (심각도 범례, 근거 법령 링크, 최근 점검 기록 재조회)	완료

12.3 MVP Acceptance Criteria

- 실제 건강기능식품 상품페이지의 DOM Text 와 상세 이미지를 수집할 수 있다. — 충족 (iframe 마켓 포함)
- 이미지 안 광고 문구를 AI 분석 입력에 포함할 수 있다. — 충족
- 공식 Product 를 식별하고 Product 에 연결된 Ingredient 와 Official Function 을 조회할 수 있다. — 충족
- COMMON 및 원료별 Rule 을 평가하고 적용 Rule 에서 ReferenceSource 를 연결할 수 있다. — 충족
- ReferenceSource 에서 현재 Claim 과 관련된 공식 근거 문단을 검색할 수 있다. — 충족
- Claim 과 공식 기능성을 의미적으로 비교하고 근거 기반 소비자 설명을 생성할 수 있다. — 충족
- 최종 Finding 을 저장하고 Side Panel 에서 조회·표시할 수 있다. — 충족
- 결과에서 원문 위치로 이동하거나 Highlight 할 수 있다. — 충족
- 공식 Product·근거를 충분히 확인하지 못한 경우 임의로 결과를 확정하지 않는다. — 충족 (미평가 건수로 별도 집계)

12.4 최종 E2E 목표 — 실측 검증 완료



위 흐름 전체가 실제 상품페이지(예: i-hi.co.kr 등 카페 24 기반 쇼핑몰)를 대상으로 End-to-End 동작함을 확인했다. 마켓별 처리시간 편차는 13 절 참고.

13. 트러블슈팅 사례 (신규)

발표 자료 "05. 트러블슈팅 및 성능 개선" 섹션의 내용을 파트별로 정리한다. 각 사례는 문제 → 원인 → 개선 → 검증 순으로 기술한다.

13.1 Frontend — iframe 내부 탐색으로 상세 데이터 수집 개선

구분	내용
문제	기존 수집 방식은 상품 페이지 바깥 DOM 중심으로 상세 영역을 탐색했는데, 일부 마켓은 상세 정보가 별도 iframe 안에 있어 상세 iframe 내부 정보가 누락되었다.
개선	상품 페이지 전체가 아니라 지정된 상세 프레임을 탐색하고, 해당 프레임에 직접 추출 코드를 실행하도록 변경했다.
검증	11 번가 실제 상세 HTML 과 모의(mock) Chrome API 로 재현·검증했다.

13.2 Backend — 규칙 판정 결과 조립 시 정보 손실 및 오염 문제

세부 내용은 6.3 절(판정 결과 조립 — 정보 손실 방지) 참고. 발표 자료 기준 4 단계 진행 경과는 다음과 같다.

단계	내용
01 문제 발견	여러 Rule 이 매칭돼도 대표 1 개만 반영되고, 나머지 판정 정보는 버려짐
02 1 차 수정과 새로운 문제	카테고리별 최대 3 개까지 노출하도록 수정했지만, 미구현 Rule 이 섞여 오염 발생
03 근본 원인 규명과 재설계	"판단 시도 안 함"과 "판단했지만 애매함"을 reasonCode 로 구분
04 검증	신규 테스트 통과 + 실측 확인. Rule 30 개 → 50 개 확장까지 로직 안정적으로 유지

13.3 AI — OCR 개선과 병렬 처리로 평가 성능 최적화

OCR 엔진 비교·교체

대상	판단 근거
Tesseract·EasyOCR	품질·누락 문제
PaddleOCR	확대 검증에서 누락·속도 문제
Google Cloud Vision	시간·추출 결과 비교 후 채택

- 작은 표본에서 실제 상품 이미지로 검증 범위를 확대했다.
- Vision 실패/키 미설정 시에는 Gemini 폴백을 유지한다.
- 규칙 평가 동시성을 4 에서 12 로 조정해 대기 시간을 줄였다 (작업 블록을 나누어 순차 실행 → 더 많은 작업을 동시 실행).

13.4 UI/UX — 소비자 친화적 개선

문제	개선
모든 문구가 같은 "확인 필요"로만 표시됨	심각도를 HIGH·CAUTION 2 단계로 차등화 — HIGH: 치료·효과 보장으로 받아들여져 판단을 크게 왜곡, CAUTION: 강조·설명 부족으로 효과 범위·근거를 오해
색 박스가 여러 개로 나뉘어 핵심이 흩어짐	광고 문구 → 주의 이유 → 근거 법령 순서로 정리하고 한 줄 요약에 집중
카드 여백이 커서 3~4 건만으로 화면이 가득 참	한 줄 목록 + 펼쳐 보기로 전환해 더 많은 결과를 한 화면에서 확인

13.5 처리 시간 개선 실측

항목	이전 → 이후	비고
이미지 글자 추출 시간 (① OCR 엔진 교체)	약 44 초 → 12.6 초	추출 글자수 30,677 자 → 29,323 자(약 96%), 한 엔진만 빈 결과를 낸 이미지 0 장
규칙 평가 시간 (② 동시성 조정)	5.9 초 → 2.9 초 (약 52% 단축)	전체 분석 8.1 초 → 5.0 초, Gemini 호출 수는 15 회로 동일

14. 알려진 이슈 및 향후 개선 (신규)

14.1 마켓(쇼핑몰)별 처리 편차

마켓	처리시간(실측)	비고
i-hi 등 카페 24 계열	5.8 ~ 13.7 초	안정적, 텍스트 100 개 이상 정상 추출
쿠팡	8.9 ~ 13.3 초	텍스트 300 개·이미지 60 장 상한에 근접해

마켓	처리시간(실측)	비고
		뒤쪽 내용이 잘릴 수 있음
네이버	23.2 초	429(요청 과다) 오류 다수 관측
G마켓	53.3 초	상세 텍스트가 18 개 내외로만 추출되어 Claim 대부분을 OCR에 의존, 429 오류 다수 — 현재 시연·안정적 사용 대상에서 제외 권장

14.2 외부 API 한도

Gemini 무료 티어는 일일 500 회 한도이며, 분석 1 건당 Gemini 호출이 12~18 회 발생한다. 사용량이 많은 날에는 한도 소진으로 분석이 실패할 수 있으며, 이 경우도 화면에는 "분석 서버에 연결할 수 없어요"로 안내되어 실제 원인(서버 정상, 한도 소진)과 사용자 안내가 불일치한다. 예비 API 키 준비 및 한도 소진 시 별도 안내 문구 분기가 필요하다.

14.3 재사용 캐시 blind spot

9.3 절 참고 — 이미지 URL 은 동일하고 실제 이미지 내용만 교체되는 경우를 현재 contentHash 구성으로는 감지하지 못한다. 이미지 콘텐츠 해시(pHash 등) 도입을 중기 과제로 둔다.

14.4 판정 안정성

동일 입력에 대해 규칙 판정이 항상 완전히 동일한 결과를 내는지는 계속 관찰 중이다. 일부 규칙은 실측 검증셋 기준 라벨 자체의 근거를 원문 대조로 재확인하며 보정하고 있으며(팀 승인 절차 운영), 해당 개선은 AI 담당(서호준) 파트에서 별도로 추적한다. 정확한 안정도 수치는 AI 파트 검증 결과를 참조한다.

14.5 향후 확장 방향

- 분석 매체 확대: SNS 광고, 숏폼, 영상, 라이브커머스 — 멀티모달 광고 검수 AI(이미지·영상·자막·음성 통합 분석) 필요
- 상품군 확대: 화장품, 일반식품, 기타 소비재 — 상품군별 기준·규칙·검증 기반 구축 필요
- Chrome 확장 프로그램 무료·오픈소스 운영을 기반으로 광고 문구·제품·평가 결과·근거 데이터를 축적
- 장기적으로 기업용 서비스(대량 광고 검수, 검수 API, 광고대행사·커머스 플랫폼 연동)로 확장 가능